

机器学习与因果推断

第三讲：有向无环图 (Directed Acyclic Graph, DAG)——用图形化方法思考因果

陈志远

中国人民大学商学院

2026-03-16

核心概念

- 概率与统计基础：随机变量、分布、条件期望
- 回归的本质： $E[Y|X]$ 是条件期望，不只是拟合线
- 预测 vs 因果：预测关注相关性，因果需要识别策略

核心概念

- 概率与统计基础：随机变量、分布、条件期望
- 回归的本质： $E[Y|X]$ 是条件期望，不只是拟合线
- 预测 vs 因果：预测关注相关性，因果需要识别策略

本节课目标：

- ① 理解有向无环图 (**DAG**) 的基本符号
- ② 掌握后门准则 (**Backdoor Criterion**)
- ③ 识别碰撞节点 (**Collider**) 及其偏误
- ④ 学会用 DAG 指导研究设计

Section 1

为什么需要 DAG?

之前的问题

- 混淆变量 (*Confounder*) 导致选择偏误
- 遗漏变量 (*Omitted Variable*) 使估计有偏
- 如何判断需要那些控制变量 (*Control Variables*)?

关键问题

控制更多变量总是更好吗?

DAG 的解决方案

- 用图形明确表示变量关系
- 系统化识别因果路径
- 指导需要控制哪些变量

核心优势

DAG 让因果假设可视化、可讨论、可检验

研究问题上大学对收入的因果效应

传统方法：控制所有可观测变量？

- 年龄、性别、种族
- 父母教育、家庭收入
- 高中成绩、能力测试
- 职业选择、婚姻状况

研究问题上大学对收入的因果效应

传统方法：控制所有可观测变量？

- 年龄、性别、种族
- 父母教育、家庭收入
- 高中成绩、能力测试
- 职业选择、婚姻状况

潜在陷阱控制“职业选择”或“婚姻状况”可能引入碰撞偏误！

- 这些变量可能是教育和收入的共同结果
- 控制它们会打开虚假路径

Section 2

DAG 基础符号

有向无环图 (**Directed Acyclic Graph, DAG**)

- 节点 (*Nodes*): 表示随机变量
- 有向边 (*Directed Edges*): 表示直接的因果效应
- 无环 (*Acyclic*): 因果只沿时间向前, 不能形成循环

有向无环图 (**Directed Acyclic Graph, DAG**)

- 节点 (*Nodes*): 表示随机变量
- 有向边 (*Directed Edges*): 表示直接的因果效应
- 无环 (*Acyclic*): 因果只沿时间向前, 不能形成循环

简单 **DAG** 示例:

- $D \longrightarrow Y$: 教育直接影响收入
- $D \longrightarrow X \longrightarrow Y$: 教育通过中介变量职业技能 (或能力) 影响收入
- $D \longleftarrow X \longrightarrow Y$: 能力同时影响教育和收入, 混淆因果关系!

链式结构：中介变量

链式路径： $D \rightarrow Z \rightarrow Y$

- D : 处理变量（如教育）
- Z : 中介变量（如职业技能）
- Y : 结果变量（如收入）

控制 Z 会阻断 D 对 Y 的真实因果效应

链式结构：中介变量

链式路径： $D \rightarrow Z \rightarrow Y$

- D ：处理变量（如教育）
- Z ：中介变量（如职业技能）
- Y ：结果变量（如收入）

控制 Z 会阻断 D 对 Y 的真实因果效应

教育回报的例子

上大学 (D) $\rightarrow$ 获得技能 (Z) $\rightarrow$ 更高收入 (Y)

- 总效应 = 直接效应 + 间接效应（通过技能）
- 如果控制“职业技能”(Z)，会低估教育总回报
- 若想估计直接效应，才需要控制中介变量

分叉结构：混淆变量

分叉路径： $D \leftarrow Z \rightarrow Y$

- Z 是 D 和 Y 的共同原因
- 造成 D 和 Y 的统计相关，但非因果
- 必须控制 Z 才能识别因果效应

分叉结构：混淆变量

分叉路径： $D \leftarrow Z \rightarrow Y$

- Z 是 D 和 Y 的共同原因
- 造成 D 和 Y 的统计相关，但非因果
- 必须控制 Z 才能识别因果效应

教育回报中的混淆因素

能力 (Z) $\rightarrow$ 上大学 (D)


能力 (Z) $\rightarrow$ 高收入 (Y)

- 能力强的人更可能上大学且收入更高
- 如果不控制能力，会高估教育效应
- 这就是遗漏变量偏误的 DAG 表示

Section 3

后门准则

后门路径 (Backdoor Path)



后门路径 (Backdoor Path)

- 因果效应: $D \longrightarrow Y$
- 后门路径: $D \longleftarrow X \longrightarrow Y$
- X 是混淆变量, 造成 D 与 Y 的虚假相关性 (*Spurious Correlation*)

后门路径 (Backdoor Path)

从处理变量 D 到结果变量 Y 的非因果路径，满足：


- 1 以指向 D 的箭头开始 (“进入后门”): $D \leftarrow \dots$
- 2 路径最终到达 Y
- 3 包含任何方向的边 ($\rightarrow$ 或 $\leftarrow$)

若 Z 满足后门准则，则：

$$P(Y|do(D)) = \sum_z P(Y|D, Z)P(Z)$$


后门路径的类型举例

不可观测的混淆变量 I




- U 不可观测
- 后门路径:
 $U \rightarrow D \rightarrow Y$
- 称后门路径是开放的 (Open Backdoor Path)

不可观测的混淆变量 II



- Becker 人力资本模型 (Becker, 1964): 教育投资 (D) 受家庭收入 (I)、父母教育水平 (E) 和其他不可观测因素 (B , e.g., 能力, 基因, 家庭氛围等) 影响
- 教育水平与家庭收入共同作用于收入 (Y)。
- B 是混淆变量
- 思考: B 会直接影响 Y 吗?


碰撞结构



- 后门路径:
 $D \leftarrow X \rightarrow Y$
- X 是碰撞节点: 当有两个变量共同影响一个结果变量时, 称该变量是碰撞节点 (Collider)
- 当控制碰撞节点 X 时, D 和 Y 会变得相关, 即使它们原本没有任何关系!


后门路径的类型举例

不可观测的混淆变量 I




- U 不可观测
- 后门路径:
 $U \rightarrow D \rightarrow Y$
- 称后门路径是开放的 (Open Backdoor Path)

不可观测的混淆变量 II



- Becker 人力资本模型 (Becker, 1964): 教育投资 (D) 受家庭收入 (I)、父母教育水平 (E) 和其他不可观测因素 (B , e.g., 能力, 基因, 家庭氛围等) 影响
- 教育水平与家庭收入共同作用于收入 (Y)。
- B 是混淆变量
- 思考: B 会直接影响 Y 吗?


碰撞结构



- 后门路径:
 $D \leftarrow X \rightarrow Y$
- X 是碰撞节点: 当有两个变量共同影响一个结果变量时, 称该变量是碰撞节点 (Collider)
- 当控制碰撞节点 X 时, D 和 Y 会变得相关, 即使它们原本没有任何关系!


后门路径的类型举例

不可观测的混淆变量 I




- U 不可观测
- 后门路径:
 $U \rightarrow D \rightarrow Y$
- 称后门路径是开放的 (Open Backdoor Path)

不可观测的混淆变量 II



- Becker 人力资本模型 (Becker, 1964): 教育投资 (D) 受家庭收入 (I)、父母教育水平 (E) 和其他不可观测因素 (B , e.g., 能力, 基因, 家庭氛围等) 影响
- 教育水平与家庭收入共同作用于收入 (Y)。
- B 是混淆变量
- 思考: B 会直接影响 Y 吗?

碰撞结构



- 后门路径:
 $D \leftarrow X \rightarrow Y$
- X 是碰撞节点: 当有两个变量共同影响一个结果变量时, 称该变量是碰撞节点 (Collider)
- 当控制碰撞节点 X 时, D 和 Y 会变得相关, 即使它们原本没有任何关系!

后门准则的直观理解

为什么叫“后门”？

想象你要从 D 走到 Y ：

- 前门是因果路径： $D \rightarrow Y$ （你想走的正路）
- 后门是混淆路径： $D \leftarrow \dots \rightarrow Y$ （偷偷绕进来的偏误）

后门准则的直观理解

为什么叫“后门”？

想象你要从 D 走到 Y ：

- 前门是因果路径： $D \rightarrow Y$ （你想走的正路）
- 后门是混淆路径： $D \leftarrow \cdots \rightarrow Y$ （偷偷绕进来的偏误）

关键洞察

后门路径造成 D 与 Y 的虚假相关 (*spurious correlation*):

- 我们看到 D 和 Y 相关
- 但这可能是通过后门路径的相关，而非真正的因果
- 控制适当的变量可以“关闭”后门，只留下因果路径

回归视角：如何实现后门准则

人力资本模型的回归实现

Becker 模型中，识别教育 (D) 对收入 (Y) 的因果效应：

朴素回归（有偏误）

$$Y_i = \alpha + \delta D_i + \varepsilon_i$$

$\hat{\delta}$ 包含教育效应 + 所有后门路径的偏误

回归视角：如何实现后门准则

人力资本模型的回归实现

Becker 模型中，识别教育 (D) 对收入 (Y) 的因果效应：

朴素回归（有偏误）

$$Y_i = \alpha + \delta D_i + \varepsilon_i$$

$\hat{\delta}$ 包含教育效应 + 所有后门路径的偏误

! 重要

满足后门准则的回归

$$Y_i = \alpha + \delta D_i + \beta_1 I_i + \varepsilon_i$$

通过控制家庭收入 I ，我们阻断了所有以 I 为节点的后门路径， $\hat{\delta}$ 成为因果效应的无偏估计。

回归如何“阻断”后门路径？

直观理解：比较 **vs** 对比

不控制 I 时：

- 比较“上大学者”和“没上大学者”的收入
- 两组在“家庭收入”上分布不同
- 观察到的差异 = 教育效应 + 家庭背景差异

控制 I 时：

- 在相同家庭收入 I 水平内比较
- 剥离 I 对 D 和 Y 的共同影响
- 只剩教育 $\rightarrow$ 收入的因果路径


数学机制

回归 $Y_i = \alpha + \delta D_i + \beta I_i + \varepsilon_i$ 中：

- ① βI_i 吸收 I 对 Y 的直接影响
- ② 残差 ε_i 与 I 无关
- ③ D 的变异分为两部分：
 - 与 I 相关的部分（后门路径） $\rightarrow$ 被控制
 - 与 I 无关的部分（因果路径） $\rightarrow$ 估计 δ

结果 $\hat{\delta}$ 反映 I 无法解释的那部分 D 对 Y 的影响

人力资本模型：完整 DAG 分析



变量说明： D = 大学教育， Y = 收入， PE = 父母教育， I = 家庭收入， B = 不可观测背景因素

人力资本模型：识别所有路径

从 D 到 Y 的四条路径：

路径	类型	状态
$D \rightarrow Y$	因果路径	我们想要估计的
$D \leftarrow I \rightarrow Y$	后门路径	需要通过控制关闭
$D \leftarrow PE \rightarrow I \rightarrow Y$	后门路径	需要通过控制关闭
$D \leftarrow B \rightarrow PE \rightarrow I \rightarrow Y$	后门路径	需要通过控制关闭

关键发现

所有后门路径都经过家庭收入 I ！
因此，仅控制 I 就足以满足后门准则。
这是最小充分调整策略。

回归实现：逐步展示

步骤 1：朴素回归（有偏）

$$Y_i = \alpha + \delta D_i + \varepsilon_i$$

估计结果：

- $\hat{\delta}_{ols} =$ 教育相关效应
- 包含真实效应 + 后门路径偏误
- 可能高估或低估真实效应

步骤 2：控制家庭收入（满足后门准则）

$$Y_i = \alpha + \delta D_i + \beta I_i + \varepsilon_i$$

估计结果：

- $\hat{\delta}_{causal} =$ 因果效应
- 后门路径被阻断
- 无偏估计（假设无其他开放后门）

如何“阻断”后门路径？

控制 I 相当于：

- 在 I 的每个水平内比较 D 对 Y 的影响
- 剥离 I 造成的 D 与 Y 的相关性
- 只剩下 $D \rightarrow Y$ 的因果路径

回归的魔法通过将 I 包含在模型中，我们实现了对 I 的条件化，从而阻断了所有经过 I 的后门路径。

为什么控制 I 就够了?


后门路径的阻断原理

后门路径必须通过某个共同原因连接 D 和 Y :

- 路径 1: $D \leftarrow I \rightarrow Y$ (经过 I)
- 路径 2: $D \leftarrow PE \rightarrow I \rightarrow Y$ (经过 I)
- 路径 3: $D \leftarrow B \rightarrow PE \rightarrow I \rightarrow Y$ (经过 I)

控制 I 的效果

- 阻断所有经过 I 的路径
- 不满足后门准则的路径被关闭
- 只剩下因果路径开放



控制 I 后, 所有后门路径被阻断

反例：当控制策略失效时

修改后的 **DAG**: B 直接影响 Y

如果在 DAG 中加入 $B \rightarrow Y$:

- 新后门路径: $D \leftarrow B \rightarrow Y$
- 这条路径不经过 I
- 仅控制 I 无法阻断这条路径
- 估计仍然有偏!

反例：当控制策略失效时

修改后的 **DAG**: B 直接影响 Y

如果在 DAG 中加入 $B \rightarrow Y$:

- 新后门路径: $D \leftarrow B \rightarrow Y$
- 这条路径不经过 I
- 仅控制 I 无法阻断这条路径
- 估计仍然有偏!

回归中的体现:

$$Y_i = \alpha + \delta D_i + \beta I_i + \varepsilon_i$$

即使控制了 I , 如果 B 直接影响 Y :

- ε_i 包含 B 的影响
- B 同时影响 D 和 Y
- D 与 ε_i 相关
- 内生性偏误仍然存在

人力资本模型：控制策略总结

控制变量	阻断的后门路径	是否满足后门准则	备注
无	无		存在遗漏变量偏误
I (家庭收入)	所有经过 I 的路径		最小充分集
$I + PE$	所有经过 I 或 PE 的路径		充分但非最小
PE 仅	$D \leftarrow PE \rightarrow I \rightarrow Y$		仍有 $D \leftarrow I \rightarrow Y$ 开放
B (若可观测)	所有路径		理想但通常不可行


人力资本模型：控制策略总结

控制变量	阻断的后门路径	是否满足后门准则	备注
无	无		存在遗漏变量偏误
I (家庭收入)	所有经过 I 的路径		最小充分集
$I + PE$	所有经过 I 或 PE 的路径		充分但非最小
PE 仅	$D \leftarrow PE \rightarrow I \rightarrow Y$		仍有 $D \leftarrow I \rightarrow Y$ 开放
B (若可观测)	所有路径		理想但通常不可行


实践启示

- 找到最小充分调整集是关键
- 控制不必要的变量会降低统计功效
- 遗漏关键混淆变量会导致偏误
- DAG 帮助我们系统化地识别关键变量

应用：教育回报的 DAG



应用：教育回报的 DAG



后门路径识别

从“教育”到“收入”：

- 后门路径 **1**：教育 $\leftarrow$ 能力 $\rightarrow$ 收入
- 后门路径 **2**：教育 $\leftarrow$ 家庭背景 $\rightarrow$ 收入
- 必须控制：能力、家庭背景

不能控制的变量

- 职业选择（碰撞节点）
- 婚姻状况（可能是结果）
- 工作经验（部分中介）

Section 4

碰撞节点与碰撞偏误

什么是碰撞节点？


碰撞结构: $D \rightarrow X \leftarrow Y$

- X 是碰撞节点 (Collider)
- D 和 Y 原本独立 (无因果路径)
- 但一旦控制 X , D 和 Y 会虚假相关!

什么是碰撞节点？

碰撞结构: $D \rightarrow X \leftarrow Y$

- X 是碰撞节点 (Collider)
- D 和 Y 原本独立 (无因果路径)
- 但一旦控制 X , D 和 Y 会虚假相关!



悖论：控制碰撞节点会创造虚假相关

名人效应：解释碰撞偏误


电影明星案例

成为电影明星 (X) 需要：

- 颜值 (D)
- 演技 (Y)

如果已有颜值，演技可以差一些


如果已有演技，颜值可以差一些



i 注记

在明星群体中：颜值与演技负相关，但这只是选择效应！

颜值与演技的“权衡”



核心洞察：在明星样本中，颜值和演技看似负相关，

但这只是碰撞偏误——两者都是成为明星的原因！

更多碰撞偏误的例子

案例 1：研究幸福感对收入的影响

- 控制”婚姻状态”会引入偏误
- 因为幸福感和收入都影响婚姻

案例 2：研究教育对健康的效应

- 控制”就业状态”需谨慎
- 可能是教育和健康的共同结果

Section 5

真实应用：歧视与碰撞偏误

常见观点

“控制职业后，性别工资差距消失或减小”

- 这是否证明不存在歧视？
- 还是职业本身就是歧视的结果？

性别工资差距的争论

常见观点

“控制职业后，性别工资差距消失或减小”

- 这是否证明不存在歧视？
- 还是职业本身就是歧视的结果？

DAG 视角

职业可能是碰撞节点：

- 性别 → 职业选择
- 能力/偏好 → 职业选择
- 歧视 → 职业选择

控制职业可能掩盖歧视的真实效应！

样本选择作为碰撞偏误

样本选择偏误

当样本本身是基于碰撞节点选择时，即使不”控制”任何变量，偏误也已存在。

例子只在明星样本中研究颜值与演技的关系

样本选择作为碰撞偏误

样本选择偏误

当样本本身是基于碰撞节点选择时，即使不”控制”任何变量，偏误也已存在。

例子只在明星样本中研究颜值与演技的关系

研究建议

使用 DAG 指导样本选择：

- ① 明确目标总体
- ② 识别选择机制
- ③ 评估选择是否基于碰撞节点
- ④ 必要时使用选择模型纠正

Section 6

两种因果框架的比较

潜在结果框架 vs DAG 框架

潜在结果框架

Rubin 因果模型

核心概念

- 每个个体的 $Y(0)$ 和 $Y(1)$
- 因果效应: $\tau_i = Y_i(1) - Y_i(0)$
- 识别假设: 无混淆、正向性、SUTVA

优势

- 精确的数学表达
- 清晰的识别条件
- 估计方法丰富

DAG 框架

Pearl 因果图

核心概念

- 节点和有向边
- 路径: 链式、分叉、碰撞
- 后门准则、do-演算

优势

- 可视化因果关系
- 系统化识别偏误来源
- 指导变量选择

两种框架的互补性

维度	潜在结果框架	DAG 框架
表达形式	数学公式	图形结构
核心问题	平均处理效应是多少?	哪些路径造成偏误?
识别条件	条件独立假设 (CIA)	后门准则、 d -分离
变量选择	基于理论判断	基于路径分析
最佳应用	估计和推断	研究设计和假设

两种框架的互补性

维度	潜在结果框架	DAG 框架
表达形式	数学公式	图形结构
核心问题	平均处理效应是多少?	哪些路径造成偏误?
识别条件	条件独立假设 (CIA)	后门准则、 d -分离
变量选择	基于理论判断	基于路径分析
最佳应用	估计和推断	研究设计和假设

! 重要

本课程的观点：两种框架互补

- 设计阶段：用 DAG 理清因果结构
- 分析阶段：用潜在结果框架进行估计

同一问题的两种视角

混淆偏误

潜在结果框架：

$$E[Y(0)|D = 1] \neq E[Y(0)|D = 0]$$

处理组和对照组的反事实不同

DAG 框架：

存在从 D 到 Y 的开放后门路径



提示

需要通过控制变量阻断

碰撞偏误

潜在结果框架：

条件化导致样本选择，破坏可比性

DAG 框架：

控制碰撞节点打开虚假路径



提示

即使该变量“看起来”相关，也不能控制

Section 7

如何用 DAG 指导研究设计

DAG 分析的五步法

步骤 1: 绘制 DAG

列出所有相关变量及其因果关系:

- 基于理论和先验知识
- 包含可观测和不可观测变量
- 讨论完善

DAG 分析的五步法

步骤 1: 绘制 DAG

列出所有相关变量及其因果关系:

- 基于理论和先验知识
- 包含可观测和不可观测变量
- 讨论完善

步骤 2: 识别目标路径

从处理变量到结果变量的直接因果路径:

- 想估计的效应
- 不要阻断这条路径!

DAG 分析的五步法

步骤 1: 绘制 DAG

列出所有相关变量及其因果关系:

- 基于理论和先验知识
- 包含可观测和不可观测变量
- 讨论完善

步骤 2: 识别目标路径

从处理变量到结果变量的直接因果路径:

- 想估计的效应
- 不要阻断这条路径!

步骤 3: 识别后门路径

找出所有非因果路径:

- 以后门箭头开始
- 标记开放的后门路径

步骤 4：确定控制策略

找出满足后门准则的变量集合：

- 阻断所有后门路径
- 不包含碰撞节点
- 不包含中介变量（除非估计直接效应）

步骤 4：确定控制策略

找出满足后门准则的变量集合：

- 阻断所有后门路径
- 不包含碰撞节点
- 不包含中介变量（除非估计直接效应）

步骤 5：敏感性分析

考虑不可观测混淆因：

- 如果有未观测的混淆变量怎么办？
- 效应估计对遗漏变量有多敏感？

案例：评估培训项目

研究设计

某公司想评估新员工培训的效果：

变量列表：

- 处理变量 D ：参加培训
- 结果变量 Y ：工作绩效
- 可能的混杂变量 C ：能力、动机、经验
- 可能的中介变量 M ：技能掌握
- 可能的碰撞变量 L ：留任状态

DAG 指导

应该控制：

- 入职前能力测试
- 工作经验
- 教育背景

不应该控制：

- 技能掌握（中介）
- 留任状态（碰撞）
- 部门分配（可能是结果）

实践：模拟数据分析

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt
from matplotlib.patches import FancyArrowPatch
import warnings
warnings.filterwarnings('ignore')

# 设置中文字体
plt.rcParams['font.sans-serif'] = ['Source Han Sans SC', 'Noto Sans SC',
                                   'WenQuanYi Micro Hei', 'SimHei']
plt.rcParams['axes.unicode_minus'] = False

np.random.seed(42)
n = 1000
true_effect = 2.0
```

实践：模拟数据分析

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt
from matplotlib.patches import FancyArrowPatch
import warnings
warnings.filterwarnings('ignore')

# 设置中文字体
plt.rcParams['font.sans-serif'] = ['Source Han Sans SC', 'Noto Sans SC',
                                   'WenQuanYi Micro Hei', 'SimHei']
plt.rcParams['axes.unicode_minus'] = False

np.random.seed(42)
n = 1000
true_effect = 2.0
```

绘制 DAG 结构

Python 绘图代码

```
# 绘制 DAG 结构
fig, ax = plt.subplots(figsize=(10, 10))
ax.set_xlim(0, 10)
ax.set_ylim(0, 10)
ax.axis('off')
```


节点位置

```
positions = {
    'C': (2, 8),      # 能力
    'D': (2, 5),      # 培训
    'M': (5, 5),      # 技能
    'Y': (8, 5),      # 绩效
    'L': (5, 2),      # 留任
}
```

节点颜色配置

生成的 DAG 图

培训效果评估的 DAG 结构



关键洞察：

- 能力 (C) 是混淆变量：影响培训和绩效
- 技能 (M) 是中介变量：培训 → 技能 → 绩效

绘制 DAG 结构

Python 绘图代码

```
# 绘制 DAG 结构
fig, ax = plt.subplots(figsize=(10, 10))
ax.set_xlim(0, 10)
ax.set_ylim(0, 10)
ax.axis('off')
```


节点位置

```
positions = {
    'C': (2, 8),      # 能力
    'D': (2, 5),      # 培训
    'M': (5, 5),      # 技能
    'Y': (8, 5),      # 绩效
    'L': (5, 2),      # 留任
}
```

节点颜色配置

生成的 DAG 图

培训效果评估的 DAG 结构



关键洞察：

- 能力 (C) 是混淆变量：影响培训和绩效
- 技能 (M) 是中介变量：培训 → 技能 → 绩效

使用 CausalGraph 包绘制 DAG

```
import networkx as nx
import matplotlib.pyplot as plt

# 创建有向图
G = nx.DiGraph()
nodes = [
    ('C', {'label': '能力 (C)', 'type': 'confounder', 'color': '#f08080'}),
    ('D', {'label': '培训 (D)', 'type': 'treatment', 'color': '#4682b4'}),
    ('M', {'label': '技能 (M)', 'type': 'mediator', 'color': '#90ee90'}),
    ('Y', {'label': '绩效 (Y)', 'type': 'outcome', 'color': '#4682b4'}),
    ('L', {'label': '留任 (L)', 'type': 'collider', 'color': '#f08080'})
]
G.add_nodes_from([(n, attr) for n, attr in nodes])

edges = [('C', 'D'), ('C', 'Y'), ('D', 'M'), ('M', 'Y'), ('D', 'Y')]
for u, v in edges:
    G.add_edge(u, v)
```

使用 CausalGraph 包绘制 DAG

```
import networkx as nx
import matplotlib.pyplot as plt

# 创建有向图
G = nx.DiGraph()
nodes = [
    ('C', {'label': '能力 (C)', 'type': 'confounder', 'color': '#f08080'}),
    ('D', {'label': '培训 (D)', 'type': 'treatment', 'color': '#4682b4'}),
    ('M', {'label': '技能 (M)', 'type': 'mediator', 'color': '#90ee90'}),
    ('Y', {'label': '绩效 (Y)', 'type': 'outcome', 'color': '#4682b4'}),
    ('L', {'label': '留任 (L)', 'type': 'collider', 'color': '#f08080'})
]
G.add_nodes_from([(n, attr) for n, attr in nodes])

edges = [('C', 'D'), ('C', 'Y'), ('D', 'M'), ('M', 'Y'), ('D', 'Y')]
for u, v in edges:
    G.add_edge(u, v)
```


回归分析：不同控制策略比较

5 种控制策略比较

```
models = {  
    '模型 1(不控制)': sm.OLS(data['performance'], sm.add_constant(data)),  
    '模型 2(控制 C)': sm.OLS(data['performance'], sm.add_constant(data[['C']])),  
    '模型 3(控制 M)': sm.OLS(data['performance'], sm.add_constant(data[['M']])),  
    '模型 4(控制 C+M)': sm.OLS(data['performance'], sm.add_constant(data[['C', 'M']])),  
    '模型 5(控制 L)': sm.OLS(data['performance'], sm.add_constant(data[['L']]))  
}
```

```
print(f" 真实效应: {true_effect:.3f}")  
print("=" * 62)
```

```
results = []  
for name, model in models.items():  
    coef = model.params['training']  
    results.append({  
        '模型': name,  
        '系数': coef
```

回归分析：不同控制策略比较

5 种控制策略比较

```
models = {  
    '模型 1(不控制)': sm.OLS(data['performance'], sm.add_constant(data)),  
    '模型 2(控制 C)': sm.OLS(data['performance'], sm.add_constant(data[['C']])),  
    '模型 3(控制 M)': sm.OLS(data['performance'], sm.add_constant(data[['M']])),  
    '模型 4(控制 C+M)': sm.OLS(data['performance'], sm.add_constant(data[['C', 'M']])),  
    '模型 5(控制 L)': sm.OLS(data['performance'], sm.add_constant(data[['L']]))  
}
```

```
print(f" 真实效应: {true_effect:.3f}")  
print("=" * 62)
```

```
results = []  
for name, model in models.items():  
    coef = model.params['training']  
    results.append({  
        '模型': name,  
        '系数': coef
```

模型评估

DAG 指导原则

模型	评估	问题	偏估计
模型 1(不控制)	有偏	包含能力 (C)	控制混淆变量：阻断后门路径，获得无偏估计
模型 2(控制 C)	正确	阻断后门路径	不要控制中介变量：除非只想估计直接效应
模型 3(控制 M)	低估	阻断间接效应	绝对不能控制碰撞变量：会引入新的偏误
模型 4(控制 C+M)	部分正确	估计直接效应	
模型 5(控制 L)	严重错误	碰撞偏误	



提示

DAG 是选择控制变量的科学依据！

Section 8

总结

① DAG 基础

- 节点表示变量，有向边表示因果
- 三种路径结构：链式、分叉、碰撞

② 后门准则

- 识别需要阻断的后门路径
- 指导控制变量选择

③ 碰撞偏误

- 控制碰撞节点创造虚假相关
- 样本选择可能引入偏误

④ 框架比较

- DAG 用于研究设计
- 潜在结果用于估计

使用 **DAG** 的检查清单

- ☐ 绘制包含所有关键变量的 DAG
- ☐ 识别处理到结果的因果路径
- ☐ 识别并阻断所有后门路径
- ☐ 检查是否意外控制了碰撞节点
- ☐ 检查是否意外阻断了中介变量
- ☐ 讨论未观测混淆因素的可能性

使用 **DAG** 的检查清单

- ☐ 绘制包含所有关键变量的 DAG
- ☐ 识别处理到结果的因果路径
- ☐ 识别并阻断所有后门路径
- ☐ 检查是否意外控制了碰撞节点
- ☐ 检查是否意外阻断了中介变量
- ☐ 讨论未观测混淆因素的可能性



提示

推荐工具

- *CausalGraph* (Python): 构建和分析因果图
- *dagitty.net*: 在线 DAG 分析和路径识别
- *ggdag* (R 包): 绘制和分析 DAG

感谢聆听!

欢迎提问与讨论!

chenzhiyuan@rmbs.ruc.edu.cn